

Uporaba metod strojnega učenja za napoved gibanja cen posameznih urnih blokov

Matematika z računalnikom

Jan Založnik
Fakulteta za matematiko in
fiziko
Jadranska ulica 19
1000 Ljubljana
jz4708@student.uni-lj.si

Mai Praskalo
Fakulteta za matematiko in
fiziko
Jadranska ulica 19
1000 Ljubljana
mp5970@student.uni-lj.si

Aleš Tavčar^{*}
GEN-I, trgovanje in prodaja
električne energije, d.o.o.
Vrbina 17
8270 Krško, Slovenija
ales.tavcar@gen-i.si

Povzetek

V tem delu smo s pomočjo metod strojnega učenja skušali napovedati gibanje cen posameznih urnih blokov. Pri tem smo uporabili pretekle podatke o gibanju cen elektrike, vremenske napovedi različnih ponudnikov ter preostalo obremenitev električnega omrežja.

1. UVOD


Električno energijo je v primerjavi z ostalimi energenti in dobrinami zelo zahtevno shranjevati, zato morata biti proizvodnja in poraba električne energije konstantno v ravnovesju. Tržni igralci tako izravnavajo svojo proizvodnjo in porabo na znotrajdnevni trg elektrike, kjer se trguje elektrika za dobavo v posameznih 15 minutnih blokih do vsega nekaj minut pred začetkom dobave. V zadnjih letih se je predvsem zaradi rasti deleža proizvodnje elektrike iz obnovljivih virov, ki je zaradi odvisnosti od vremena težko napovedljiva, dejavnost na znotrajdnevni trg močno povečala, igralci na teh trgih pa vedno večji delež odločitev prepuščajo umetni inteligenci.

V ekonomskem smislu je elektrika surovina, s katero je mogoče trgovati na trgu električne energije **PX** (angl. *Power Exchange*). Kot je že bilo omenjeno je električno energijo zelo težko shranjevati in hkrati morata biti proizvodnja in poraba neprestano v ravnovesju.

Na trgu dobimo pošteno ceno z načelom ponudbe in povpraševanja, kar pomeni, da proizvajalci podajo ponudbo (koliko električne energije lahko proizvedejo in za kakšno ceno), nasprotno porabniki električne energije podajo povpraševanje (koliko električne energije bodo porabili in koliko so zanj pripravljeni plačati).

Tako dobimo dve krivulji in stičišče teh predstavlja ceno

^{*}Mentor



Slika 1: Graf ponudbe in povpraševanja

elektrike, kar prikazuje slika 1. Zavedati se moramo, da so na trgu mogoče tudi negativne cene.

Negativne cene so cenovni signal na veleprodajnem trgu električne energije, ki se pojavi, ko visoka nefleksibilna proizvodnja električne energije zadovolji nizko povpraševanje. Neprilagodljivih virov energije ni mogoče hitro in stroškovno učinkovito izklopiti in znova zagnati. Prav tako je cenovno zahtevno zaustaviti obnovljive vire energije. Cene padajo z nizkim povpraševanjem in signalizirajo generatorjem na zmanjšanje proizvodnje, da se izognejo preobremenitvi omrežja. Na dnevnem in znotraj dnevnem trgu lahko tako cene padejo pod ničlo.

2. TRGOVANJE Z ELEKTRIČNO ENERGIJO

V Evropi imamo več različnih električnih trgov, največja sta Nord Pool (v 16 državah) in Epex Spot (v 13 državah), vendar Slovenija ni del nobenega od teh. Povezovanje evropskih trgov omogoča prost pretok električne energije čez meje, kar poveča konkurenčnost na trgu ter s tem dosežemo boljše učinkovitost. S čezmejnimi trgovanjem torej vplivamo na socialno blaginjo vseh Evropejcev. V tem delu smo se osredotočili le na Nemčijo, ki je del obeh izmed omenjenih trgov. Prav tako so bile na teh trgih izvedene vse transakcije o tr-

govanju, ki jih bova uporabila pri analizi in napovedovanju.

Evropska Unija se zavzema, da se bo delež obnovljivih virov do leta 2030 dvignil iz 25% na več kot 50%. Prav tako je cilj, da bodo proizvedli zadostno količino energije tudi ko ne bo vetra ali sonca. Eden izmed načinov je shranjevanje električne energije, ko veterne in sončne elektrarne pridelajo presežek.

2.1 Dnevni in znotraj dnevni trg


Dnevni trg se upravlja prek dražbe, ki poteka enkrat na dan, skozi celotno leto. Na tej dražbi se trguje za vse ure naslednjega dne. Naročila so prijavljena s strani udeležencev na trgu, in sicer imajo udeleženci čas do 12:00 UTC, da oddajo vsa ponudbe in povpraševanja za naslednji dan. Na podlagi nakupnih naročil se vzpostavi krivulja povpraševanja, na podlagi prodajnih naročil pa krivulja ponudbe za vsako uro naslednjega dne. Tržna klirinška cena (MCP), ki odraža ponudbo in povpraševanje, leži na presečišču obeh krivulj.

Na znotraj dnevnem trgu udeleženci trgujejo neprekinjeno, 24 ur na dan, z dostavo še isti dan. Takoj, ko se ujemata naročilo za nakup in prodajo, se posel izvede. Z električno energijo je mogoče trgovati do 5 minut pred dostavo in prek urnih, polurnih ali četrturnih pogodb. Ker to omogoča visoko stopnjo prilagodljivosti, člani uporabljajo znotraj dnevni trg za prilagoditve v zadnjem trenutku in za uravnoteženje svojih pozicij bližje dejanskemu času. Čezmejno trgovanje je bistveno pri trgovanju znotraj dneva.

2.2 Podatki

2.2.1 Podatki o cenah na dnevnem in znotraj dnevnem trgu

Zaradi nedostopnosti podatkov tako dnevnega in znotraj dnevnega ter preostale obremenitve omrežja so ti pridobljeni iz strani GEN-I. Posamezni trgi sicer ponujajo podatke in programske vmesnike za delo z njimi, a so le-ti plačljivi.



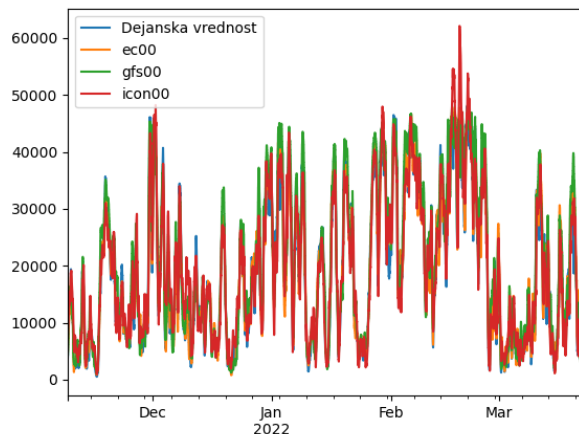
Slika 2: Dnevni in znotraj dnevni trg

Podatki obeh trgov zajemajo vrednosti med 9. 11. 2021 in 23. 3. 2022. Pri dnevnem trgu je za vsako uro naslednjega dneva določena cena, medtem ko pri znotraj dnevnem trgu so vrednosti za vsa trgovanja, ki so se zgodila na borzi Epex Spot.

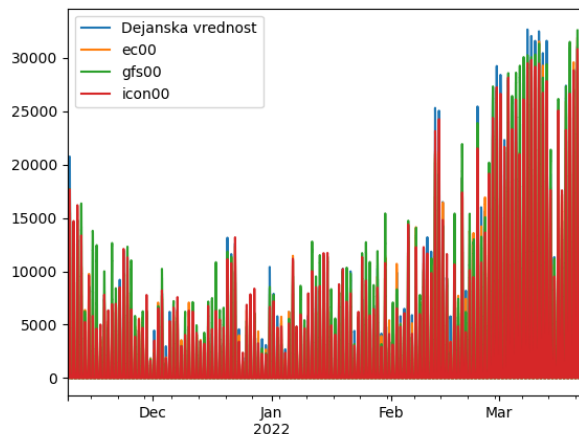
2.2.2 Eksogeni podatki

Kot je bilo že omenjeno, bo imelo vreme zaradi vedno večjega deleža obnovljivih virov vedno večji vpliv na cene in

proizvajanje elektrike. Največji delež obnovljivih virov sta v letu 2021 predstavljala veterna in sončna energija, zato smo za napoved proizvedene energije pridobili veterne in sončne napovedi treh različnih ponudnikov, in sicer European Centre for Medium-Range Weather Forecasts, Global Forecast System ter Deutscher Wetterdienst.




Slika 3: Podatki o veterni energiji



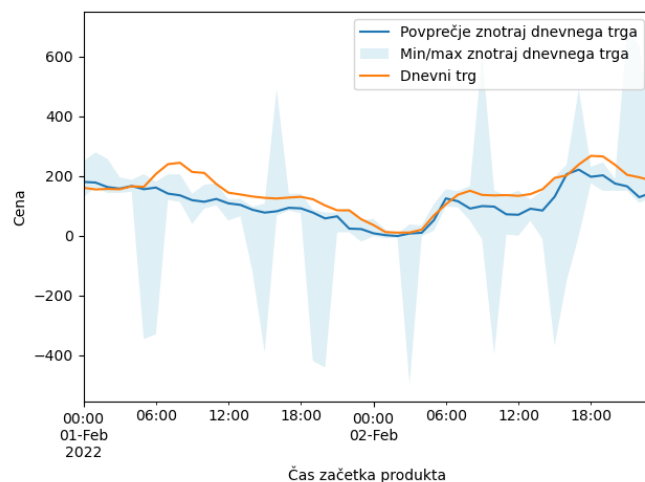
Slika 4: Podatki o sončni energiji

2.2.3 Podatki o preostali obremenitvi omrežja


Vsi izmed teh podatkov vsebujejo napovedi narejene ob polnoči za ure celotnega dneva, kot dejanske pretekle vrednost v 15 minutnem intervalu.



Slika 5: Podatki o preostali obremenitvi omrežja



Slika 7: Povprečna cena produkta eno uro pred zaprtjem



Slika 6: Povprečna cena na znotraj dnevnem trgu

2.3 Analiza podatkov

Preden smo se lotili razvijanja napovednih modelov, smo analizirali podatke in s tem preverili ali bodo ti sploh lahko uporabni.

2.3.1 Cena produkta na dnevnem trgu kot napoved cene znotraj dnevnega trga


Na prvem mestu nas je zanimalo ali je cena na dnevnem trgu dobra kot izhodiščna napoved cene na znotraj dnevnem trgu.

Če zelo poslušimo model in uporabimo le eno ceno, oz. povprečno ceno vseh produktov znotraj časovnega obdobja na znotraj dnevnem trgu, namesto povprečja posamičnih cen produktov, bomo najverjetneje podcenili dejansko tveganje trgovanja, kar je razvidno na grafu 6, ko sta cena na dnevnem trgu in povprečna cena na znotraj dnevnem trgu med seboj zelo blizu, a hkrati obstaja velik razmak med minimalno in maksimalno ceno na znotraj dnevnem trgu v istem časovnem obdobju.


Zato napovedujemo povprečne cene posamičnih produktov znotraj časovnega intervala nekaj časa pred zaprtjem trgovanja s tem produktom, saj s tem zmanjšamo tveganje trgovanja (7). Poleg tega, je tako bolj koristna informacija, ki jo pridobimo prek dnevnega trga, ki vsebuje vrednosti za vsako uro.

Izkazalo se je, da je razlika med njima v obliki normalne distribucije, s središčem blizu ničle oz. med njima je več manjših kot večjih razlik.

Zato smo predpostavili, da je cena na dnevnem trgu primerna za uporabo napovedi cene na znotraj dnevnem trgu.



Slika 8: Histogram in distribucija razlik med ceno na dnevnem in znotraj dnevnem trgu



Slika 9: Standardna deviacija po urah

Tabela 1: Korelacija podatkov s spremembo cene

Ponudnik	Vetrna ener.	Sončna ener.	Preostala obrem.
ec00	-0.245	-0.162	0.333
gfs00	-0.219	-0.131	0.306
icon00	-0.147	-0.001	

2.3.2 Korelacija vetrne in sončne energije ter preostale obremenitve s spremembo cene

Kot preprost indikator vpliva podatkov o vetrni in sončni energiji ter preostali obremenitvi na spremembo v ceni smo preverili korelacijo med njimi, ki je prikazana v tabeli 1.


Korelacija med vremenskimi podatki in spremembo v ceni, je negativna, saj to pomeni večjo proizvodnjo za vetrne in sončne elektrarne in posledično nižjo ceno elektrike. Medtem ko obstaja pozitivna korelacija med preostalo obremenitvijo omrežja in spremembo v ceni, saj to pomeni, da je bilo manj proizvedene elektrike in se s tem zviša cena na trgu.

2.3.3 Standardna deviacija po urah in dnevu in vpliv cene produkta na ceno sledečih produktov


Da smo izvedeli ali je ura produkta pomenljiv podatkom, smo preverili kakšna so standardna odstopanja v spremembi cene (Slika 9).

Podobno je tudi pri standardni deviaciji po dnevih v tednu, kjer se odstopanja povečajo v začetku tedna, medtem ko se proti koncu tedna zmanjšujejo.


Standardna deviacija se giblje od približno 20 pa tudi do čez 50 v določenih urah, kar kaže na večjo volatilitnost nekaterih urnih produktov.



Slika 10: Standardna deviacija po dnevih



Slika 11: Avtokorelacija




Slika 12: Delna avtokorelacija

Če imajo cene prejšnje ure vpliv na ceno sledečih produktov, smo preverili s pomočjo avtokorelacije (Slika 12).


Očitno je, da imajo vpliv, a prek delne avtokorelacije je razvidno, da je daleč najbolj informativen podatek cena produkta eno uro prej, kamor je vpliv prejšnjih ur v večini že prenešen.

2.3.4 Sezonskost znotraj dnevnega trga

Opravili smo tudi analizo sezonskosti znotraj dnevnega trga s pomočjo statsmodels knjižnice, kjer se je izkazalo, da obstaja tako tedenska kot mesečna sezonskost.



Slika 13: Tedenska sezonskost



Slika 14: Mesečna sezonskost

3. NAPOVEDNI MODELI

3.1 Modeli časovnih vrst

Časovne vrste so nizi podatkovnih točk, indeksirani oziroma navedeni v nekem časovnem vrstnem redu. Najpogostejše gre za nabor zaporednih točk, ki so na časovni komponenti enakomerno porazdeljeni (imajo isti časovni razmik). Gre torej za zaporedje podatkov v diskretnem času.

Analiza časovnih vrst obsega metode za analizo podatkov, tako da pridobimo smiselne statistične značilnosti. S pomočjo analiz lahko potem poiščemo model, ki se podatkom najbolj prilega in s pomočjo njega napovemo prihodnje vrednosti časovne vrste. Skratka napovedovanje časovnih vrst je uporaba modela za napovedovanje prihodnjih vrednosti na podlagi predhodno opazovanih vrednosti.

3.1.1 SARIMA

Seasonal autoregressive integrated moving average oziroma **SARIMA** je razširjen model, bolj preprostega modela **ARMA**. Oba modela se uporabljata za napovedovanje podatkov časovnih vrst ali pa tudi samo za boljše razumevanje podatkov. Pri obeh potrebujemo stacionarnost, da lahko pridemo do čim boljših napovedi. Do stacionarnosti pridemo z odstranitvijo morebitnega trenda in sezone, to lahko storimo na veliko načinov, najpogostejša načina sta diferenciranje (lahko tudi večkratno diferenciranje) in pa logaritmiranje (kjer moramo paziti da nimamo negativnih vrednosti). Da preverimo stacionarnost časovne vrste lahko uporabimo Dickey–Fullerjev test (**ADF**), kjer ugotovimo, da so podatki stacionarni, če je p vrednost manjša od 5%. Na dobljenih podatkih potem narišemo grafe, kot so auto-correlation function (**ACF**) in Partial auto-correlation function (**PACF**), kjer lahko razberemo najboljše vrednosti za modela AR in MA. Pri AR tako ugotovimo, koliko prejšnje vrednosti vplivajo na naslednje, MA pa indicira regresijsko napako. Ostaneta nam še S in I iz kratice SARIMA, ki pomenita "seasonality" in pa "integrated", kjer podamo vrednosti za sezone (npr. sedem dnevna, mesečna itd.) in še informacijo o tem ali smo podatke diferencirali.

Tako smo s pomočjo modela SARIMA napovedali vrednosti posameznih urnih blokov, vendar smo ugotovili, da napoved ni preveč dobra, saj nimamo podatkov v enakomernih časovnih razmikih. Podatki namreč prikazujejo celotno trgovanje produktov, kar seveda ni v ekvidistančnih intervalih. Problem smo nato skušali rešiti z glajenjem funkcije in vzeti enakomerni časovni razmik, vendar s tem sistem izgubi določene informacije in pripomore k slabši napovedi. Slika 15 prikazuje primer napovedi enega urnega bloka.

Želeli smo napovedati tudi naslednjih 24 ur znotraj dnevnega trga. To smo storili tako, da smo za vsak urni blok izračunali povprečje produkta v zadnji uri. Model smo nato prilagodili glede na te podatke in uporabili lastnost harmoničnosti residualov, s tem smo dobili napoved na sliki 16.

Podobno smo cene napovedali tudi brez uporabe harmoničnosti in napoved narisali na dejanske cene zadnjih 24 ur (slika 17).

Ker nas je zanimala točnost modela pri posameznih naborih podatkov, smo za vse časovne vrste pripravili tabele in pripadajoče grafe, na katerih je prikazana točnost naše napovedi. To smo storili tako, da smo preverili, koliko se

končna napovedana vrednost razlikuje od dejanske zadnje vrednosti na borzi. Rezultate smo tako predstavili v obliki absolutnih napak ter v procentih, koliko povprečno zgrešimo v nekem časovnem obdobju (slika 18).

Ter še graf kako se spreminja absolutna napaka v odvisnosti od velikosti začetnih podatkov (slika 19).

3.1.2 Prophet

Facebook Prophet oziroma Prophet je model za napovedovanje vrednosti različnih časovnih vrst. Prednost tega modela je, da stacionarnost ni pogoj za uspešno napoved, prav tako ni potrebno, da ima časovna vrsta enakomerne časovne razmike.

Primer napovedi enega urnega bloka smo narisali na sliki 20.

S pomočjo Proheta smo prav tako poskušala napovedati zadnje vrednosti urnih blokov. Kot zanimivost smo tudi primerjali napoved v času vojne (februar 2022), kjer je bila volatilitetnost na trgu veliko večja, in pa napoved v "normalnih" razmerah. Ker si želimo tudi praktično koristnost naših metod, smo model učili na preteklih podatkih do dve uri pred koncem trgovanja za posamezni urni blok. Tako nam še ostane dovolj časa, da na trg vstopimo s kratko oziroma dolgo pozicijo. Ker bi bilo možno, da zelo oddaljeni podatki o trgovanju za določen urni blok vplivajo negativno na napoved, smo tudi tukaj spreminjali nabor podatkov.


Podobno kot pri modelu ARIMA, smo tudi tukaj iskali najboljše razmerje med rezultati (o točnosti napovedi) in absolutno napako.

3.2 Orbit

Orbit je prav tako model za napovedovanje vrednosti časovnih vrst, kjer je mogoče z dodajanjem različnih informacij možno vplivati na izboljšavo napovedi. Tega prej omenjena modela ne zmoreta. Primer napovedi enega urnega bloka smo narisali na sliki 25.


Podobno kot pri modelih SARIMA in Prophet, nas je zanimala natančnost napovedanih vrednosti, če spreminjamo množico zgodovinskih podatkov. Ponovno smo analizo naredili na manj stabilnih podatkih (slika 11) in na bolj predvidljivih (slika 10). Ter zopet primerjali vrednosti pri različnih napovednih intervalih (slika 29).

ARIMA napoved za blok 11.11.2021 ob 12:00

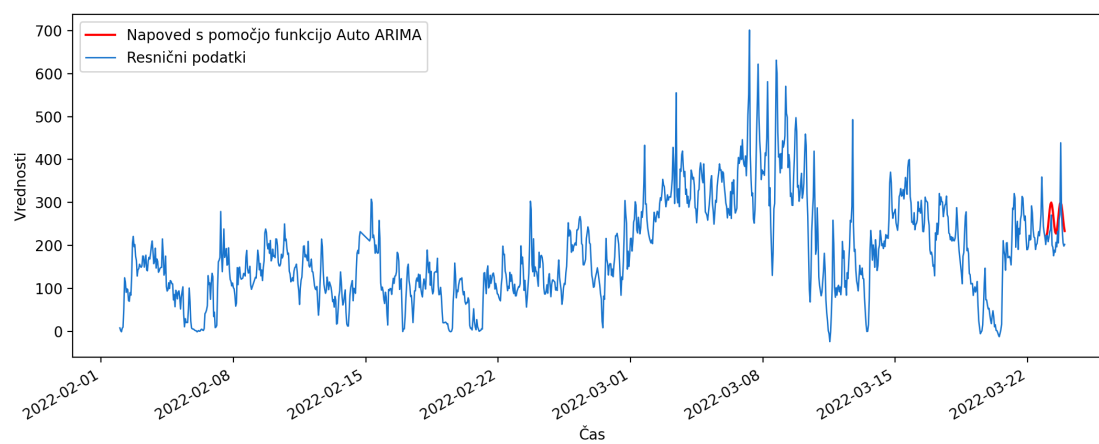


Slika 15: Napoved za urni blok (SARIMA)

Napoved znotraj dnevnega trenda 24 ur

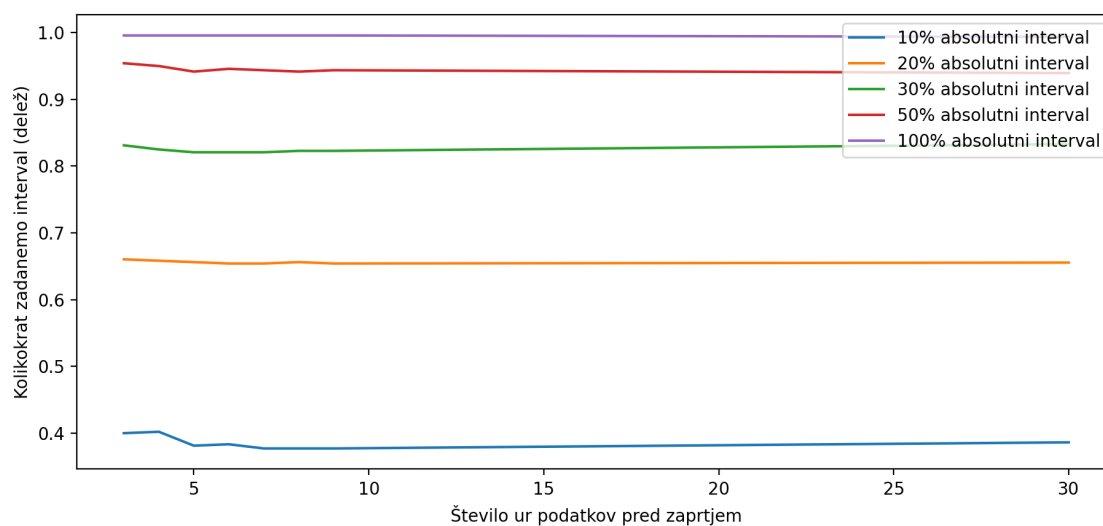


Slika 16: Napoved 24 ur na trgu znotraj dneva (SARIMA)

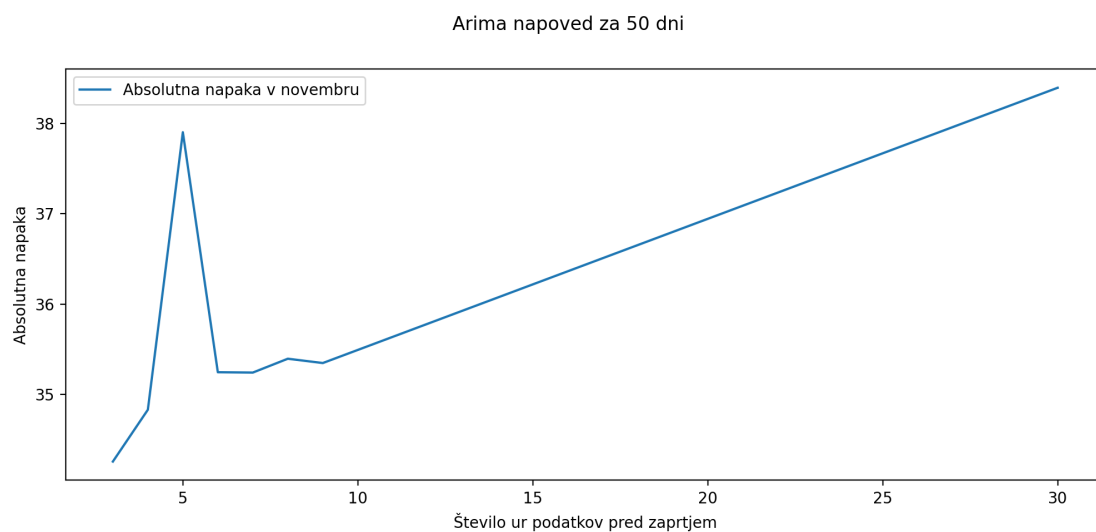


Slika 17: Napoved 24 ur na trgu znotraj dneva (2.2.2022-24.3.2022) (SARIMA)


Arima napoved za 50 dni (november)



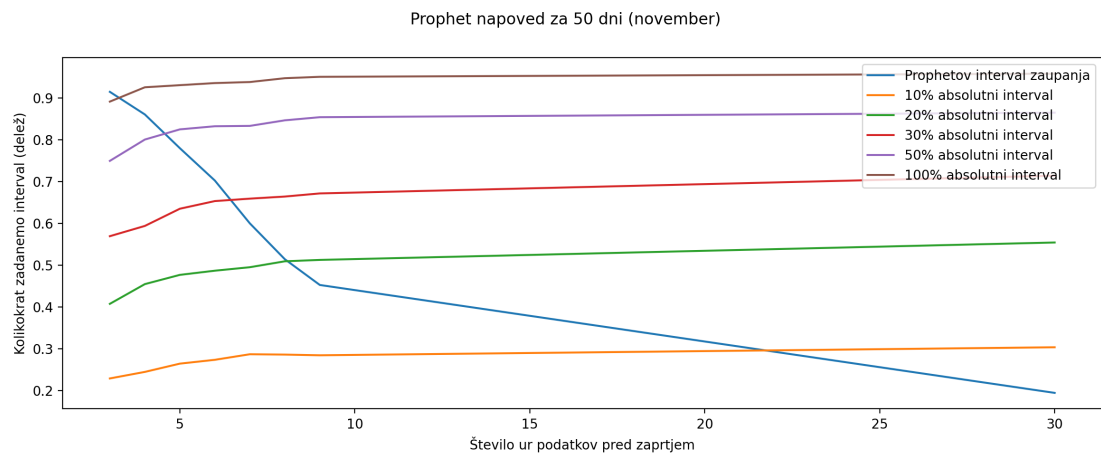
Slika 18: Napoved ARIMA za 50 dni (november)



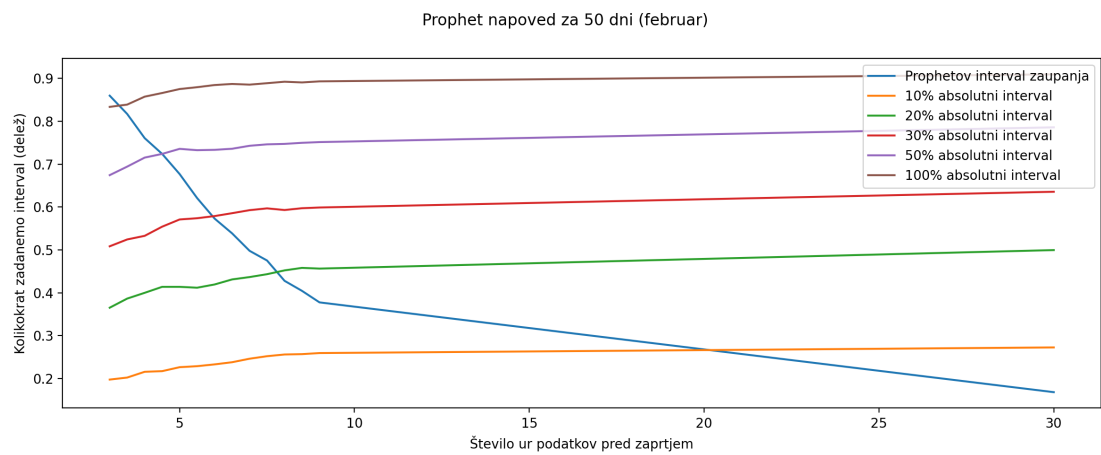
Slika 19: Napoved ARIMA za 50 dni (november)



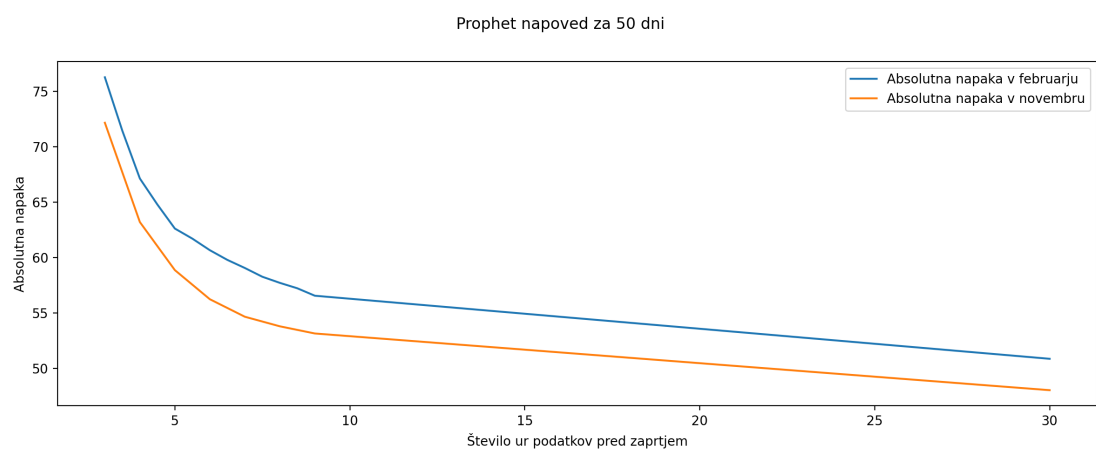
Slika 20: Napoved Prophet za urni blok (10.11.2021 ob 00:00)



Slika 21: Napoved Prophet za 50 dni (november)




Slika 22: Napoved Prophet za 50 dni (februar)




Slika 23: Absolutna napaka za Prophet


Prophet napoved za 50 dni (november)




Slika 24: Napoved Prophet v spreminjanju napovednega časa



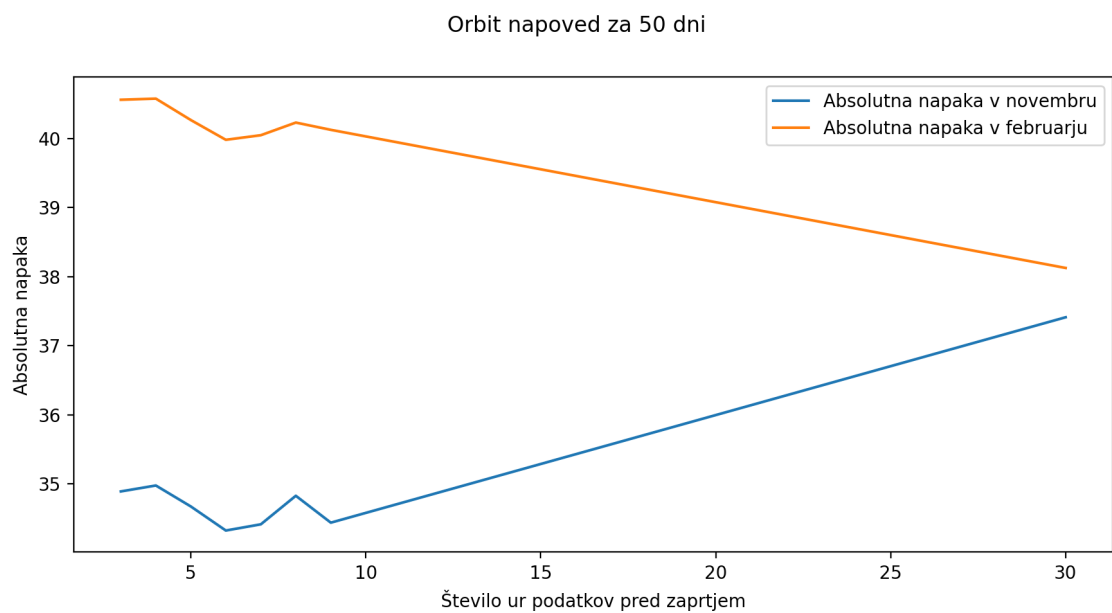
Slika 25: Napoved Orbit za urni blok (10.11.2021 ob 00:00)




Slika 26: Napoved Orbit za 50 dni (november)



Slika 27: Napoved Orbit za 50 dni (februar)



Slika 28: Absolutna napaka za Orbit



Slika 29: Napoved Orbit v spreminjanju napovednega časa

3.3 Modeli odločitvenih dreves

Modeli odločitvenih dreves gradijo odločitvena drevesa z odločitvami je res / ni res za lastnosti podatkov, ki razdelijo podatke, tako da se čim bolj zmanjša varianca teh podatkov za lastnost, ki jo želimo napovedati. Te odločitve so nato uporabljene za napovedi še ne videnih podatkov.

Za lastnosti našega najbolj osnovnega modela, smo uporabili le podatek o ceni iz dnevnega trga ter uro in dan produkta, ki ga napovedujemo. V nadaljevanju bo tak model označen z **osnovni model**.

Temu smo dodali še podatke za celoten dan dnevnega trga ter prejšnjih 24 ur znotraj dnevnega trga. S tem v realnem svetu dopuščamo le eno uro časa za napoved in dejansko trgovanje z napovedanim produktom. V nadaljevanju bo tak model označen z **model 24h**.

Modelu 24h, smo dodali še vremenske podatke in preostalo obremenitev omrežja, in sicer spremembe med napovedjo in dejanskimi vrednostmi za prejšnjih 24 ur ter napoved za uro produkta, ki ga napovedujemo. V nadaljevanju bo tak model označen z **model 24h exo**.

Model 24h in model 24h exo, smo nato nadgradili še s podatki o dnevnem trgu sledečega dneva, kar pa je primerno le za napoved produktov med 16 in 24 uro, saj so šele takrat ti podatki dejansko na voljo. Te dva modela bosta v nadaljevanju označena z **model 24h next** in **model 24h next exo**.

Ti modeli so bili uporabljeni tako za regresijski problem napovedi cene, kot za dva klasifikacijska problem spremembe cene. Pri preostem se klasificira le padec (razred 0) ali naraščaj cene (razred 1), pri drugem pa je sprememba razdel-

jena v intervalu $(-60, 60)$ v korakih po 10 (razredi od 1 do 13), vrednosti izven tega intervala pa imajo določen razred glede na kateri strani izven intervala so, in sicer razred 0, če so pod intervalom in razred 1, če so nad intervalom.

3.3.1 Naključni gozd

Prvi izmed uporabljenih modelov je naključni gozd, ki zgradi več odločitvenih dreves, tako da za vsakega vzame le del podatkov in njihovih lastnosti, kot napoved pa uporabi najbolj pogosto napoved tako ustvarjenih odločitvenih dreves (glasovanje). Napovedi so bile opravljene tako, da se je razdelilo podatke tako, da je preostal le 1 dan ali pa 20 dni

Tabela 2: Točnost naključnega gozda (regresija)

Model	MAE	MAPE	RMSE
baseline (1 dan)	38.58	16.54	44.09
baseline (20 dni)	49.72	36.31	36.84
24h (1 dan)	36.31	-37.09	53.57
24h (20 dni)	38.99	15.22	57.02
24h exo (1 dan)	30.15	13.79	40.67
24h exo (20 dni)	36.84	-18.54	53.58
24h next (1 dan)	21.59	8.44	24.75
24h next (20 dni)	38.99	15.22	57.02
24h next exo (1 dan)	17.1	6.77	20.22
24h next exo (20 dni)	41.71	15.88	59.59

Rezultati za vse regresivne modele naključnega gozda so predstavljeni v tabeli 2, za vse klasifikacije pa v tabeli 3.

Tabela 3: Točnost naključnega gozda (klasifikacija)

Model	2 razreda. (%)	14 razredov. (%)
baseline (1 dan)	0.875	0.125
baseline (20 dni)	0.57	0.126
24h (1 dan)	0.5	0.041
24h (20 dni)	0.6	0.139
24h exo (1 dan)	0.46	0.041
24h exo (20 dni)	0.6	0.19
24h next (1 dan)	0.5	0.125
24h next (20 dni)	0.66	0.187
24h next exo (1 dan)	0.71	0.25
24h next exo (20 dni)	0.66	0.16

3.3.2 XGBoost

XGBoost je model, ki v osnovi deluje zelo podobno kot naključni gozd, največja razlika pa je v tem, da ta ne uporablja glasovanja, ampak sekvenčno gradi čim boljši model z gradientnim spustom.

Tabela 4: Točnost XGBoost (regresija)

Model	MAE	MAPE	RMSE
baseline (1 dan)	37.23	15.93	43.58
baseline (20 dni)	52.91	12.29	70.21
24h (1 dan)	28.02	12.05	36.34
24h (20 dni)	40.86	-45.29	57.94
24h exo (1 dan)	43.43	17.21	55.70
24h exo (20 dni)	41.14	-22.58	59.81
24h next (1 dan)	13.14	5.55	16.66
24h next (20 dni)	52.16	18.06	89.42
24h next exo (1 dan)	20.16	8.34	24.10
24h next exo (20 dni)	53.28	17.58	82.35

Rezultati za vse regresivne modele XGBoost so predstavljeni v tabeli 4, za vse klasifikacijske pa v tabeli 5.


Tabela 5: Točnost XGBoost (klasifikacija)

Model	2 razreda. (%)	14 razredov. (%)
baseline (1 dan)	0.75	0.125
baseline (20 dni)	0.60	0.127
24h (1 dan)	0.75	0.083
24h (20 dni)	0.59	0.134
24h exo (1 dan)	0.625	0.16
24h exo (20 dni)	0.62	0.141
24h next (1 dan)	0.5	0.125
24h next (20 dni)	0.66	0.159
24h next exo (1 dan)	0.875	0.125
24h next exo (20 dni)	0.66	0.118


3.3.3 Vpliv lastnosti na napoved pri najboljših modelih

Najpomembnejše lastnosti pri najboljšem regresivnem modelu (XGBoost 24h next (1 dan)) so prikazane na sliki 31. Vrednosti "trd_price_mean" predstavljajo povprečno urno ceno produkta na znotraj dnevnem trgu, medtem ko "trd_price" in "trd_price_next_day" predstavljajo vrednosti dnevnega trga za napovedan in sledeč dan.

Vpliv lastnosti na klasifikacijo pa je prikazan na sliki, za najboljši klasifikacijski model (Naključni gozd baseline (1 dan)).



Slika 30: Povprečna pomembnost lastnosti pri XGBoost 24h next (1 dan) regresiji



Slika 31: Vpliv lastnosti na klasifikacijo pri Naključni gozd baseline (1 dan) klasifikaciji

4. ZAKLJUČEK

Pomembno je poudariti da je analiza, ki smo jo naredili s pomočjo časovnih vrst SARIMA, Prophet in Orbit, samo informativne narave in se lahko natančnost modelov v prihajajočih časovnih obdobjih močno spremeni. Pri sami natančnosti napovedi in velikosti napake se je najbolje izkazal model SARIMA, podobne rezultate je prikazal tudi Orbit, daleč najslabše se je odrezal Prophet. Zato bi za nadaljnje delo priporočali, da se uporabita modela SARIMA in Orbit, pri kateremu bi bilo koristno še dodati trend prejšnjega urnega bloka.

Pri modelih odločitvenih dreves se je za najboljšega pri regresiji izkazal model **24h next day**, zato za nadaljnje delo na tem problemu priporočamo nadgradnjo tega modela tako s podatki o vremenski in sončni energiji ter preostali obremenitvi omrežja za napovedan dan, kot tudi za sledeč dan. Kot smo mi zastavili modele, **24h next exo** za naslednji dan vsebuje le podatke o dnevnem trgu, ne pa tudi ostalih napovedi. napotki za nadaljnje delo

DODATEK

Za to stranjo se nahajajo še vsi dodatni rezultati modelov.

Urni zamiki (X-2)	3	4	5	6	7	8	9	30
Absolutna napaka	34,25	34,83	37,90	35,24	35,24	35,39	35,34	48,03
10% interval	40,00	40,20	38,12	38,33	37,70	37,70	37,70	30,33
20% interval	66,04	65,83	65,62	65,41	65,41	65,62	65,41	55,41
30% interval	83,12	82,50	82,08	82,08	82,08	82,29	82,29	71,41
50% interval	95,41	95,00	94,16	94,58	94,37	94,16	94,37	86,50
100% interval	99,58	99,58	99,58	99,58	99,58	99,58	99,58	99,58

Tabela 6: Tabela povprečij posameznih intervalov za 50 dni od 10. novembra 2021 (SARIMA)

Urni zamiki (X-2)	3	4	5	6	7	8	9	30
Absolutna napaka	72,18	63,21	58,87	56,24	54,66	53,80	53,15	48,03
Prophet interval (%)	91,48	86,07	78,00	70,25	60,00	51,41	45,25	19,41
10% interval	22,87	24,43	26,41	27,33	28,66	28,58	28,41	30,33
20% interval	40,73	45,45	47,66	48,66	49,50	50,91	51,25	55,41
30% interval	56,92	59,93	63,50	65,33	65,91	66,41	67,16	71,41
50% interval	74,95	80,06	82,50	83,25	83,33	84,66	85,41	86,50
100% interval	89,14	92,57	93,08	93,58	93,83	94,75	95,08	95,83

Tabela 7: Tabela povprečij posameznih intervalov za 50 dni od 10. novembra 2021 (Prophet)

Urni zamiki (X-2)	3	3,5	4	4,5	5	5,5	6	6,5	7	7,5	8	8,5	9	30
Absolutna napaka	76,28	71,45	67,14	64,80	62,62	61,71	60,67	59,79	59,06	58,27	57,72	57,23	56,56	50,86
Prophet interval (%)	85,94	81,68	76,05	72,37	67,67	62,08	57,29	53,85	49,79	47,52	42,79	40,45	37,77	16,84
10% interval	19,78	20,25	21,59	21,74	22,67	22,90	23,32	23,82	23,64	25,23	25,62	25,71	25,96	27,27
20% interval	36,53	38,65	40,00	41,39	41,39	41,19	41,94	43,12	43,67	44,34	45,22	45,81	45,64	49,95
30% interval	50,84	52,43	53,27	55,41	57,09	57,38	57,88	58,55	59,26	59,68	59,29	59,71	59,88	63,55
50% interval	67,42	69,41	71,51	72,23	72,37	73,55	73,23	73,32	73,57	74,26	74,60	74,70	74,95	78,56
100% interval	83,33	83,86	85,71	86,56	87,49	87,91	88,42	88,67	88,51	88,85	89,19	89,02	89,27	90,90

Tabela 8: Tabela povprečij posameznih intervalov za 50 dni od 10. februarja 2022 (Prophet)

Urni zamiki (V smeri napovedi)	0,5	1	1,5	2	2,5	3	3,5	4
Absolutna napaka	43,28	40,07	49,43	49,88	57,72	52,68	60,13	57,03
Prophet interval (%)	13,25	15,83	21,08	24,41	23,91	28,25	27,75	31,66
10% interval	38,41	37,41	33,00	29,25	26,66	25,41	26,33	27,50
20% interval	61,58	61,91	54,75	55,00	49,00	51,41	46,91	49,58
30% interval	75,25	75,75	69,91	69,91	65,16	67,41	63,33	66,25
50% interval	88,58	90,08	86,16	80,75	83,91	81,50	83,16	80,50
100% interval	95,08	97,33	95,33	95,00	93,58	94,16	92,75	93,66

Tabela 9: Tabela povprečij posameznih napovednih intervalov za 50 dni od 10. novembra 2021 (Prophet)

Urni zamiki (X-2)	3	4	5	6	7	8	9	30
Absolutna napaka	34,88	34,97	34,67	34,32	34,41	34,82	34,43	37,41
10% interval	40,00	39,02	40,13	40,41	39,16	40,27	39,58	40,20
20% interval	65,41	65,27	65,55	65,69	65,55	65,83	65,97	65,16
30% interval	80,55	80,41	80,41	80,41	80,41	80,27	78,66	79,41
50% interval	92,63	92,77	92,77	92,63	92,63	92,77	92,63	92,25
100% interval	98,88	98,75	98,88	98,33	98,47	98,61	98,33	98,58

Tabela 10: Tabela povprečij posameznih intervalov za 50 dni od 10. novembra 2021 (Orbit)

Urni zamiki (X-2)	3	4	5	6	7	8	9	30
Absolutna napaka	40,55	40,57	40,26	39,97	40,04	40,22	40,12	38,12
10% interval	35,67	35,38	35,57	35,46	35,18	35,31	35,91	38,91
20% interval	59,50	59,22	59,62	59,91	59,61	59,73	57,91	56,91
30% interval	73,87	74,30	74,01	73,94	74,13	74,41	78,12	77,12
50% interval	86,98	86,85	86,96	86,38	86,64	86,99	87,19	88,19
100% interval	95,94	96,12	95,87	95,79	95,80	95,88	96,08	97,08

Tabela 11: Tabela povprečij posameznih intervalov za 50 dni od 10. februarja 2022 (Orbit)

Urni zamiki (V smeri napovedi)	0,5	1	1,5	2	2,5	3	3,5	4
Absolutna napaka	27,95	34,75	36,40	37,79	38,65	40,27	41,05	41,70
10% interval	51,08	42,33	41,16	39,75	37,08	37,58	36,66	36,75
20% interval	76,16	68,08	65,91	65,75	64,33	62,66	62,66	62,00
30% interval	87,41	82,16	81,25	79,41	79,00	78,16	77,75	77,83
50% interval	95,58	93,16	92,91	93,00	92,58	92,25	91,83	91,58
100% interval	98,75	98,41	98,50	98,75	98,91	98,58	98,91	98,75

Tabela 12: Tabela povprečij posameznih napovednih intervalov za 50 dni od 10. novembra 2021 (Orbit)